



Report du PROCOM

Learning Path Analysis

Version n°1, le 24/10/2025

Auteurs : GUILLOU Pol, KHEBBEB Samy, SALAME Hajar, SORO Asma



IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

Sommaire

1. Organisation des tâches	2
2. Création d'un nouveau git	2
3. Traitement des données	2
4. Création d'un graphe par étudiant	3

1. Organisation des tâches

Après avoir fait un point avec les responsables du projet complexe “Learning Path Analysis” le jeudi 16 octobre, nous avons listé une série de trois grands points à traiter :

- La création d’un nouveau git basé sur le nom de domaine “gitlab.imt-atlantique.fr” qui regrouperait à la fois les données que nous aurions nettoyées, ainsi que les scripts développés lors de ce projet ;
- Le nettoyage des données fournies par les encadrants du projet. Ces données sont présentes sous deux formes : les fichiers .csv qui contiennent la liste des étudiants ainsi que les fichiers .log qui contiennent la liste des actions effectuées par ces mêmes étudiants ;
- La création de premiers graphes qui permettent de représenter le parcours de consultation de ressources pédagogiques de chaque étudiant, en visualisant chaque cours par lesquels ils sont passés.

Pour cette première semaine plus “pratique” nous avons simplement réparti les tâches techniques entre les membres de notre groupe :

- Hajar s’est occupée de créer le nouveau projet git et de nettoyer les fichiers .csv ;
- Asma et Pol se sont chargés de regrouper puis de séparer les fichiers .log ;
- Samy s’est servi de ces nouveaux fichiers de log pour créer les premiers graphes montrant les parcours de consultation de ressources pédagogiques des étudiants.

2. Création d’un nouveau git

Pour mieux organiser notre travail et garder une trace claire de l’avancée du projet, nous avons décidé de créer un nouveau dépôt Git. Cet espace nous permettra de centraliser toutes les données, les documents nécessaires à l’étude ainsi que les différents scripts que nous développerons au fil du projet.

Grâce à cet outil, les encadrants pourront suivre facilement notre progression, tandis que les membres du groupe pourront collaborer plus efficacement. Chacun pourra y déposer ses contributions, consulter celles des autres et travailler en toute cohérence sur les différentes parties du projet.

En plus de faciliter la gestion du travail en équipe, ce dépôt nous aidera à gagner en organisation, à éviter les pertes de fichiers et à assurer une continuité fluide dans le développement du projet.

3. Traitement des données

a. Traitement des fichiers CSV

Avant de pouvoir analyser les données, nous avons commencé par une étape de nettoyage des deux fichiers fournis par les groupes 1 et 2. L’objectif était d’obtenir des jeux de données clairs, homogènes et faciles à exploiter.

Nous avons constaté que certaines colonnes de notes (“Note test TP”, “Note contrôle continu” et “Moyenne”) étaient au mauvais format : les valeurs étaient enregistrées comme du texte, avec des virgules à la place des points décimaux. Nous avons donc converti ces données pour qu’elles soient reconnues comme des nombres, ce qui permet de les traiter correctement par la suite.

Nous avons également uniformisé les intitulés de diplômes, qui variaient d’un étudiant à l’autre, afin de regrouper les formations similaires sous des catégories communes. Enfin, nous avons supprimé la colonne “Établissement l’année précédente”, jugée non pertinente pour notre analyse.

Cette étape nous a permis d'obtenir deux bases de données cohérentes et prêtes à être exploitées pour la suite du projet.

b. Regroupement des fichiers de log

Au départ de ce projet, nous avons, pour chaque promotion d'étudiants, un fichier de log pour jour où les étudiants s'étaient connectés au serveur hébergeant les cours de l'UE INF_210.

Dans un premier temps l'idée était de regrouper, pour chaque groupe d'étudiant, tous les fichiers de log en un seul gros fichier qui ne contiendrait que les informations qui sont utiles à traiter. Pour faire cela, nous avons créé un script python "clean-move-logs.py" qui répond à cette demande en effectuant les étapes suivantes :

- On appelle ce script avec comme paramètre le chemin du dossier qui contient le dossier des logs (par exemple group1) ;
- Le script parcourt ensuite tous les fichiers ayant comme extension ".log" puis sélectionne les lignes qui concernent des fichiers .html et qui sont à l'origine d'étudiants. Ainsi, nous éliminons toutes les requêtes capturées par le serveur qui ne nous intéressent pas. Toutes les lignes qui sont gardées par le script sont ensuite envoyées dans un fichier "students.log" ;
- Enfin, on supprime de ce nouveau fichier les colonnes dont nous ne nous servirons pas pour la suite de notre projet, c'est-à-dire l'adresse IP d'où provient la requête, ainsi que trois valeurs capturées par le serveur qui n'ont pas d'importance ici.

c. Split du fichier pour avoir un fichier par étudiant

À cette étape du projet, nous avons souhaité disposer d'un fichier de log distinct pour chaque étudiant afin de pouvoir réaliser plus facilement des analyses individuelles et représenter les graphes par étudiants.

Pour cela, nous avons développé un script Python intitulé "move-by-students.py". Ce script prend en entrée les fichiers students.log générés précédemment pour chaque groupe d'étudiants (group1 et group2).

- D'abord, Il parcourt ensuite chaque ligne de ces fichiers et extrait l'identifiant de l'étudiant présent au début de la ligne.
- Ensuite, à partir de cet identifiant, le script crée automatiquement un fichier dédié à chaque étudiant dans un dossier spécifique à son groupe par exemple, les fichiers du groupe 1 sont enregistrés dans data/logs_by_student/group1, et ceux du groupe 2 dans data/logs_by_student/group2.

Ainsi, à l'issue de cette étape, chaque étudiant dispose de son propre fichier de log, contenant uniquement ses requêtes, ce qui facilitera grandement les traitements et analyses ultérieures.

4. Création d'un graphe par étudiant

a. Modélisation et filtrage des parcours de consultation de ressources

Nous allons déjà essayer de produire la première version des "parcours de consultation des ressources pédagogiques" sous forme de graphe pondéré, un par étudiant :

- Un nœud du graphe correspond à une ressource consultée par l'étudiant.

- L'arête allant du nœud correspondant à la ressource A au nœud correspondant à la ressource B aura comme poids le temps passé par l'étudiant sur la ressource A avant de passer à la ressource B.

Les timestamps des fichiers .log nous permettront d'évaluer la durée passée sur chacune des ressources. Nos graphes pourront également admettre des cycles : en effet il peut arriver qu'un étudiant revienne sur une ressource qu'il a déjà consultée au cours de son parcours.

Pour simplifier la lisibilité des graphes, nous allons émettre une hypothèse : **les clics rapides (< 1 min de temps de consultation) sont de la navigation, les clics longs sont du temps d'étude**. Ainsi on ne représentera que les arêtes dont le poids est > 1 min. Cela nous permettra d'effacer beaucoup de bruit relié à la navigation, qui n'apporte aucune information pertinente sur le parcours de consultation de ressources, et qui nuit à la lisibilité du graphe.

Des exemples de premiers graphes seront prochainement présents sur le repository GitLab.

b. Visualisation et interactivité futures

Par manque de temps dans cette phase initiale, nous avons concentré nos efforts sur la conception et le filtrage rigoureux des graphes d'apprentissage (le cœur de l'analyse). Cependant, nous avons effectué une lecture de fond d'articles clés sur la visualisation de données et l'analyse de parcours. Dans une prochaine itération, nous prévoyons d'intégrer ces connaissances pour explorer des méthodes plus avancées, afin d'optimiser la représentation visuelle des graphes et, idéalement, de les rendre interactifs pour une exploration plus riche des données.

c. Veille Scientifique et Conceptualisation du Modèle

Actuellement, nous n'avons pas encore identifié de terme unique ou de modèle conceptuel parfaitement établi dans la littérature scientifique qui décrive précisément le type de graphe pondéré par le temps que nous avons conçu.

Néanmoins, le concept de "**Directly Follows Graph**" (DFG) est celui qui se rapproche le plus de notre approche méthodologique.

Un DFG est un graphe orienté où les nœuds représentent les activités (dans notre cas, les ressources pédagogiques) et les arêtes représentent la succession directe des activités. Traditionnellement, le poids d'une arête dans un DFG est la fréquence à laquelle la transition entre une ressource A et une ressource B se produit.

Nous avons adapté ce concept en remplaçant la pondération par la fréquence par la durée de consultation. Cette adaptation permet de refléter non pas la popularité de la transition, mais son importance cognitive ou le temps d'étude effectif.

Nous continuons notre veille bibliographique pour trouver un modèle qui englobe cette notion de pondération temporelle dans l'analyse des parcours d' "apprentissage".