



Rapport PROCOM
Learning Path Analysis

Rapport n°2, le 19/12/2025

Auteurs : GUILLOU Pol, KHEBBEB Samy, SALAME Hajar, SORO Yiré Asma



IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

1. Formulation des hypothèses via des distributions

Pour les trois hypothèses suivantes :


- Le groupe 1 représente les étudiants de la première promotion brestoise dont les données ont été recueillies - 2023/2024
- Le groupe 2 représente les étudiant de la seconde promotion (Brest + Rennes) - 2024/2025


a. Hypothèse 1 - “Les étudiants n'utilisent pas les ressources de manière uniforme.”

Nous avons réalisé un histogramme définissant le temps passé sur les différentes ressources.

Résultats :

Ressources	Temps passé
project_part2	459873.0
project_specifications	416869.0
project_part1	269421.0
practice_docker	256940.0
lecture_normalization	248880.0
lecture_conceptual_modeling	240587.0
technical_environment_home	200323.0
project_part3	194407.0
practice_jpa	191588.0
index	171073.0





Interprétation statistique :

Ce sont les ressources sur lesquelles **le plus de temps cumulé** a été passé par l'ensemble des étudiants.

Interprétation pédagogique :

- Les **ressources liées au projet** dominent très nettement ;
- Les étudiants passent beaucoup de temps sur :
 - la **spécification** ;
 - les **différentes parties du projet**.
- Les ressources **pratiques techniques** (Docker, normalisation) sont également centrales.

Cela suggère que le projet agit comme un moteur principal de l'apprentissage, structurant l'usage des autres ressources.

b. Hypothèse 2 - "Les distributions sont différentes entre les groupes."

Ex. : les étudiants qui réussissent passent proportionnellement plus de temps sur les ressources "data" ou "practice".

Méthode : Distance de Kullback-Leibler (KL divergence).

KL mesure **combien une distribution de probabilité P diffère d'une autre distribution Q**.

On l'utilise quand on compare **deux vecteurs de probabilités**. Par exemple : P = distribution du temps d'un étudiant sur les ressources, Q = distribution moyenne d'un groupe.

Interprétation :

- **0** → distributions identiques ;
- Plus KL grand → plus P et Q sont différentes ;
- Valeur seule n'a pas d'échelle intuitive absolue (on compare plutôt KL entre paires).

Résultats :

- groupe 1 → 0.814038 ;
- groupe 2 → 1.713216

Interprétation statistique :

- Les étudiants de **groupe 1** ont une distribution d'usage **proche du profil moyen de leur groupe**
- Les étudiants de **groupe 2** s'en éloignent **deux fois plus**

Interprétation pédagogique :

Les étudiants du groupe 2 ont des parcours plus hétérogènes et moins alignés sur le profil pédagogique dominant. À l'inverse : Le groupe 1 suit un parcours plus cohérent et homogène.

La divergence KL plus élevée observée dans le groupe 2 suggère une moindre adéquation entre leur comportement d'apprentissage et le parcours pédagogique moyen, ce qui peut refléter des stratégies moins efficaces ou une difficulté à s'approprier la structure du cours.

c. Hypothèse 3 - "Certaines ressources discriminent les groupes."

Exemples :

- Les étudiants qui échouent passent plus de temps sur les prérequis ;
- Les étudiants qui réussissent passent plus de temps sur les pratiques.

Méthode : Test de Wilcoxon / Mann-Whitney

Mann–Whitney compare deux échantillons indépendants pour savoir si les valeurs d'un groupe tendent à être plus grandes que celles de l'autre, sans supposer de normalité.

C'est une alternative non paramétrique au t-test.

- H_0 (null) : les deux distributions ont la même probabilité de donner des valeurs supérieures (ou, plus formel, la probabilité qu'une observation prise au hasard dans le groupe A soit plus grande que celle du groupe B est 0.5).
- H_1 (alternative) : une des deux séries a tendance à donner des valeurs plus élevées.

Interprétation :

- Petit U → forte différence (les rangs d'un groupe plus élevés que l'autre).
- p-value associée : si $p < \alpha$ (ex. 0.05), rejette H_0 → les deux groupes diffèrent.

Résultats:

Ressources utilisées de manière significativement différente avec une p-value < 0.05 (cf figure ci-dessous).

resource	p_value	mean_group1	mean_group2
prerequisite_data_2025	0.00000	0.0	460.4
prerequisite_techenv	0.00000	698.2	0.0
prerequisite_data	0.00000	692.7	0.0
documentation_si	0.00000	406.0	0.0
prerequisite_archiweb	0.00000	331.4	0.0
prerequisite_techenv_2025	0.00000	0.0	369.1
project_part4	0.00000	555.5	0.0
project_home	0.00000	938.7	421.9
prerequisite_archiweb_2025	0.00000	0.0	332.5
pres	0.00004	0.0	319.1
project_part2	0.00014	4410.5	3973.9
practice_spring	0.00031	1741.4	1202.6
fproject_part3	0.00064	3.7	0.0
project_presentation	0.00074	672.8	1577.2
lecture_validity	0.00594	322.1	162.8
practice_jpa	0.00939	2438.0	1275.8
project_part1	0.01130	3358.9	1838.1
documentation_programming	0.01252	616.5	457.1
index	0.01351	1702.8	1439.0
lecture_software_architecture	0.01432	1200.1	520.1
practice_docker	0.01733	2631.3	2114.6
technical_environment_home	0.02010	2426.8	1411.3
lecture_relation_model	0.02823	174.2	0.1
practice_json	0.03238	773.8	465.9
activity_relational_model	0.03860	1147.6	865.8
lecture_technical_architecture	0.04373	992.0	674.9

Ressources de prérequis (très significatives)

Exemples : prerequisite_data_2025, prerequisite_techenv, prerequisite_archiweb

Interprétation pédagogique :

Un groupe mobilise fortement les prérequis, l'autre presque pas.

C'est un signal qui peut indiquer :

- Un besoin de rattrapage ;
- Des lacunes initiales (peut-être par rapport à la provenance des étudiants) ;
- Une dépendance aux bases.

Ressources projet

Exemples : project_home, project_part1, project_part2,..

Observation :

- Le **groupe 1** passe **beaucoup plus de temps** sur les parties structurantes du projet ;
- Le **groupe 2** est plus dispersé ou moins engagé

Interprétation pédagogique :

Le groupe 1 investit davantage les activités de synthèse et de production, ce qui est cohérent avec une meilleure appropriation des compétences.

Ressources techniques et pratiques

Exemples : practice_jpa, practice_docker, practice_spring, technical_environment_home

Interprétation pédagogique :

Les étudiants du groupe 1 s'engagent davantage dans les ressources pratiques, ce qui suggère une stratégie orientée vers la mise en œuvre et l'entraînement.

2. Formulation des hypothèses via des graphes

a. Hypothèse 1 - “Les élèves ayant des parcours d'apprentissage ‘atypiques’ par rapport à leur classe ont tendance à moins bien réussir l’UE.”

Nous nous sommes intéressés à 3 classes différentes : la classe de FIP de l'année 1 (uniquement Brest), de l'année 2 (Brest) et de l'année 2 (Rennes).

Pour pouvoir accepter ou rejeter cette hypothèse, il nous faut déjà pour chaque classe un graphe qui servira de base de comparaison.

Nous avons donc construit un **Consensus Graph** pour chaque classe : c'est un graphe qui représente le parcours moyen d'une classe. On se base sur un seuil de 25%, ainsi le graphe ne gardera que les transitions (arcs qui représentent le passage d'une ressource à une autre) qui ont été faites par plus de 25% des étudiants de la classe. Ce seuil a été choisi après plusieurs essais avec différents seuils ; le problème étant que pour un seuil trop élevé, on perd trop d'information car il est rare que des chemins soient pris par une majorité d'étudiants. Un seuil trop bas n'aurait pas de sens au vu de ce qu'on aimerait avoir comme information. Le seuil de 25% est un plutôt bon compromis entre lisibilité et information retenue.

Les 3 consensus graph sont disponibles en .html sur le git (graphs > consensus_graphs)

Le script **distance_consensus_indiv.py** se charge de mesurer la distance entre le graphe d'un étudiant et le graphe consensus de la classe auquel il appartient. La distance de Jaccard a été choisie plutôt que la GED (Graph Edit Distance, disponible sur NetworkX) car cette dernière utilise un algorithme NP-difficile, qui est de complexité trop élevée pour tous nos graphes, qui admettent beaucoup de noeuds et d'arcs. La distance de Jaccard est une mesure de similarité pour deux ensembles de données. Dans notre cas, la distance vaut 1 si l'étudiant n'a rien en commun avec le consensus de sa classe, et 0 dans le cas contraire (étudiant = consensus, ce qui est extrêmement improbable).




Le script renvoie un fichier **analyse_distances_jaccard.csv** (disponible dans le dossier docs) qui indique pour chaque étudiant la distance entre son graphe d'apprentissage avec le graphe de consensus de sa classe, avec également d'autres métriques.

Une fois cela fait, nous pouvons nous intéresser à notre hypothèse en introduisant la note finale de l'UE pour chaque étudiant.

Le script **plot_correlation.py** crée des visualisations (disponibles dans docs > plots_analyse) qui pourraient nous permettre de valider ou rejeter notre hypothèse initiale.

Résultats et analyses :

Voici les visualisations que crée le script **plot_correlation.py** :



On peut relever plusieurs éléments d'après ces visualisations :

- Les étudiants de Rennes sont plus proches de leur consensus, comme prévu : en effet les étudiants de Rennes sont beaucoup plus encadrés et guidés que ceux de Brest pour leur parcours d'apprentissage.
- La classe de FIP Brest A1 admet 3 étudiants très atypiques. Il serait intéressant de consulter leur parcours plus en détail.
- On observe une **légère corrélation** entre la distance d'un étudiant à son consensus et la note finale qu'il obtient à l'UE : un élève qui a un parcours atypique par rapport à sa place aurait tendance à moins bien réussir l'UE.
- Ce n'est pas pour autant qu'un parcours atypique correspond forcément à une note plus basse : en effet les meilleurs étudiants affichent une grande diversité de stratégies.

Axes d'améliorations :

- Biais de Rennes : nous nous sommes aperçus que les élèves de Rennes ont tous eu des bonnes notes (> 14), contrairement à Brest où c'est plus disparate. Il serait bon dans un premier temps d'exclure la classe rennaise pour notre test d'hypothèse car ce groupe peut biaiser nos analyses.
- Différencier la note d'examen de la note du projet : la note d'examen semble être plus pertinente que la note de projet, cette dernière étant plus subjective et à l'appréciation du correcteur. Au lieu de s'intéresser à la moyenne de l'UE, il serait bon de considérer uniquement la note de l'examen plutôt que la moyenne de l'UE (qui prend donc en compte la note du projet)

Une fois ces ajustements effectués, nous pourrions valider ou rejeter cette hypothèse avec sérénité.

b. Hypothèse 2 - "Les formations suivies par les étudiants avant l'IMT Atlantique influence leur résultats dans cette matière"

Cette seconde hypothèse à laquelle nous pourrions répondre grâce à l'étude des graphes nous semble intéressante car elle permettra de comparer un plus grand nombre de groupes entre eux (5 groupes) comparé aux hypothèses précédentes. De plus, nous pouvons penser que les connaissances avec lesquelles un étudiant démarre l'UE pourraient influencer la manière dont il traite les différentes ressources. Nous pourrions donc découper cette hypothèse en deux sous-tâches avec l'analyse du parcours puis des notes, et mettre en corrélation les résultats obtenus dans ces deux missions.

Bien que nous ayons eu moins de temps pour étudier en détail cette hypothèse, nous avons commencé à réfléchir à la manière dont nous pourrions l'aborder en janvier.

- La première méthode à laquelle nous pensons est celle utilisée pour l'hypothèse n°1 qui met en avant les graphes (cf 2.a). Nous pourrions utiliser la distance entre les graphes pour connaître la divergence moyenne entre un étudiant ayant suivi une formation X et le graphe moyen des étudiants des deux promotions réunies ;
- La seconde méthode repose sur l'algorithme PageRank développé par Google pour mesurer l'importance d'un nœud dans un graphe. Dans sa version originale, le sommet

d'un graphe représente une page web, et les arcs représentent les hyperliens qui permettent de passer d'une page à une autre. L'objectif est, à partir des ces graphes, d'attribuer un score à chaque page web en fonction de sa popularité. Par exemple, une page web citée par une seule page très importante aura un score élevé. Dans notre cas, nous pourrions utiliser cet algorithme pour voir, pour chaque ressource :

- Si elle est souvent visitée ;
- Si elle est atteinte par des ressources qui sont elles-mêmes centrales ;
- Si elle est située sur des chemins récurrents.

Nous pourrions ainsi constater quelles ressources structurent le parcours d'apprentissage d'un étudiant, sans regarder simplement le temps passé sur une ressource. Cette seconde méthode nous permettrait d'observer si les ressources centrales sont les mêmes entre les groupes d'étudiants analysés. Ainsi, il serait possible de mieux anticiper les ressources importantes pour un étudiant en fonction de sa formation d'origine.

Points auxquels il faudra faire attention :

Comme pour le 2.a, il faudra faire attention aux biais que cette hypothèse entraîne, notamment avec la distribution des étudiants entre les différents groupes. En effet, nous allons nous retrouver avec des groupes plus ou moins importants en fonction des formations, et il faudra être très précautionneux avec les groupes de petites tailles qui peuvent plus facilement être impactés par les outliers (valeurs extrêmes).

c. Hypothèse 3 - “Le genre des étudiants influe sur la manière dont ils abordent les ressources / sur leurs résultats”

Bien que cette hypothèse soit intéressante, nous avons décidé de ne pas la traiter en priorité, à cause de la disproportion entre les deux groupes étudiés. En effet, sur 109 étudiants au total nous ne retrouvons que 15 femmes dans les données collectées. Il y aurait donc 13% des données dans un groupe et 87% des données dans l'autre groupe. Les moyennes pour un groupe aussi petit risque d'être instable et plus difficilement interprétable en cas d'outlier. Si nous souhaitons entraîner un modèle par la suite, nous pourrions créer des données artificielles pour avoir deux groupes de taille similaire, mais la taille de notre dataset aurait pour effet que la diversité des profils ne serait pas augmentée. C'est pour ces raisons que nous avons décidé, après en avoir parlé avec Mme SEGARRA, de laisser de côté cette hypothèse pour l'instant, et de revenir dessus dans la suite de notre projet si le temps nous le permet.