



Rapport PROCOM
Learning Path Analysis

Rapport n°3, le 02/03/2026

Auteurs : GUILLOU Pol, KHEBBEB Samy, SALAME Hajar, SORO Yiré Asma



IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

Script proportion_L-P_shuffle.py

Ce script retourne un fichier *proportion_L-P_shuffle.csv* permettant de connaître la proportion des transitions (L-L, L-P, P-L, P-P) pour l'ensemble des étudiants brestois. Pour faire cela, on définit au début du script un dictionnaire qui contient toutes les ressources relatives à l'UE. Chaque ressource est répartie entre les trois thèmes de l'UE, puis catégorisée comme étant un cours "lecture" ou une activité pratique "practice".

Le fichier *proportion_L-P_shuffle.csv* contient les colonnes suivantes :

Login_LDAP | Cohorte | Cursus | Note_TP | L-L | L-P | P-L | P-P

Script proportion_L-P_shuffle_par_cursus.py

Ce script retourne un fichier *proportion_L-P_shuffle_par_cursus.csv* permettant d'avoir la proportion des transitions (L-L, L-P, P-L, P-P) par cursus (GEII, CPGE/ATS, Mesures Physiques, R&T, Informatique).

Il utilise pour cela l'output du script *proportion_L-P_shuffle.py*, et regroupe les proportions des transitions par cursus en faisant la moyenne pour chacun d'eux.

Le fichier *proportion_L-P_shuffle_par_cursus.csv* possède ces colonnes :

Cursus | L-L (proportion) | L-P | P-L | L-L | P-P | Effectif du cursus

Script divergence_KL_etudiant_vs_cursus.py

Ce script réalise l'analyse comparative en mesurant mathématiquement l'écart entre la stratégie d'apprentissage de chaque étudiant et les profils de référence des différents cursus (y compris le sien). Pour ce faire, il utilise la divergence de Kullback-Leibler (KL), une mesure permettant d'évaluer la distance entre deux distributions de probabilités (dans notre cas la distribution des différents types de transitions entre l'étudiant et le profil type du cursus)

Le fichier *divergence_KL_etudiant_vs_cursus.csv* possède ces colonnes :

Student_ID | Note_TP | Cursus_Origine | Dist_KL_CPGE/ATS | Dist_KL_GEII | Dist_KL_Informatique | Dist_KL_MP | Dist_KL_RT

Script divergence_KL_etudiant_vs_reussite.py

Ce script compare, pour chaque étudiant, son “profil de proportions” (les 4 colonnes L-L, L-P, P-L, P-P) à deux profils de référence (Réussite et Échec) en calculant une divergence de Kullback-Leibler (KL), puis il sort un fichier *divergence_KL_etudiant_vs_reussite.csv* avec les distances et le groupe le plus proche.

Le fichier *divergence_KL_etudiant_vs_reussite.csv* possède ces colonnes :

Student_ID | Note_TP | Dist_KL_Réussite | Dist_KL_Échec | Plus_Proche

Script proportion_LP_par_reussite.py

Ce script sert à **construire les profils “Réussite” et “Échec”** (moyennes des proportions L-L / L-P / P-L / P-P) à partir du fichier étudiant *proportion_L-P_shuffle.csv*, puis à les enregistrer dans *proportion_L-P_par_reussite.csv*.

Le fichier *proportion_L-P_par_reussite.csv* possède ces colonnes :

Groupe | L-L | L-P | P-L | P-P | Effectif

Script Calcul pagerank.py

Dans ce script, on commence par croiser les logs de navigation web des étudiants avec leurs cursus d'origine, récupérés via des fichiers CSV. On effectue d'abord un filtrage rigoureux des données, en ignorant les temps d'inactivité trop longs et les pages sans valeur analytique comme l'index ou l'accueil. À partir des parcours restants, on construit des graphes orientés pour modéliser concrètement les transitions de page en page, en les segmentant par groupe et par diplôme d'origine. C'est à cette étape qu'on applique l'algorithme PageRank : cela nous permet d'identifier et de pondérer les pages qui sont véritablement centrales dans la navigation. Pour finir, on utilise ces métriques pour profiler chaque étudiant, en lui attribuant un score de navigation basé sur la pertinence des pages qu'il a consultées, puis on exporte l'ensemble de ces résultats au format CSV.

Script analyse_pagerank.py

Dans ce second script, on exploite les résultats précédents pour générer automatiquement des visualisations graphiques. On commence par fusionner les scores de navigation

(PageRank) avec les notes académiques des étudiants. À partir de ces données croisées, on produit quatre figures de synthèse : un palmarès des ressources les plus utiles, une carte de chaleur illustrant les préférences par cursus d'origine, des boxplot comparant les volumes d'activité, et un nuage de points modélisant l'impact de la qualité de navigation sur la note finale. L'objectif est de transformer les données brutes en graphiques directement exploitables pour l'analyse.