



Rapport PROCOM
Learning Path Analysis

Rapport n°4, le 26/03/2026

Auteurs : GUILLOU Pol, KHEBBEB Samy, SALAME Hajar, SORO Yiré Asma



IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

Introduction

Ce quatrième et dernier rapport du Projet Complexe *Learning Path Analysis* présente les derniers avancements et résultats obtenus. Il s'inscrit dans la continuité des travaux précédents en proposant une analyse des comportements des étudiants, notamment dans leur manière de naviguer entre les ressources pédagogiques et les différents thèmes.

Plusieurs pistes d'analyse ont été explorées au cours de ce projet. Nous avons notamment cherché à vérifier différentes hypothèses, comme l'influence du temps passé sur les ressources sur la réussite des étudiants. Cependant, les résultats obtenus sur ces aspects se sont révélés peu concluants ou difficiles à interpréter de manière robuste. Pour cette raison, ces analyses ne seront pas approfondies dans ce rapport.

Nous avons donc choisi de concentrer notre étude sur trois approches complémentaires. La première repose sur l'analyse des transitions entre types de ressources (Lecture, Practice) et entre thèmes, afin de caractériser les comportements moyens des étudiants. La seconde, au cœur de ce rapport, s'appuie sur des techniques de *pattern mining*, permettant d'extraire automatiquement des séquences de navigation fréquentes. Cette approche vise à identifier des parcours typiques et à mettre en évidence des différences structurelles entre les étudiants en réussite et ceux en échec. Enfin, la dernière approche mobilise l'algorithme PageRank pour évaluer le poids structurel et l'influence de chaque ressource au sein du flux global d'apprentissage. Alors que les précédentes méthodes étudient les séquences locales, le PageRank nous a permis d'identifier les concepts fondateurs sur lesquels s'appuient les étudiants, ainsi que leurs points de blocage majeurs. Nous avons ainsi pu analyser comment cette hiérarchie de l'information varie selon les différents cursus d'origine suivis avant l'IMT et selon la réussite ou l'échec à l'examen.

Enfin, ces analyses sont accompagnées d'outils de visualisation permettant d'explorer les résultats et de mieux comprendre les dynamiques d'apprentissage observées.

Passage entre les types de ressource et les thèmes

1. Présentation des scripts

Dans le rapport précédent, nous avons introduit les premiers scripts qui permettaient de voir le taux de passage d'un type de ressource (Lecture ou Practice) vers un autre, et ce, pour chaque étudiant. Après en avoir discuté avec les encadrants, nous avons décidé d'étendre cette analyse aux passages d'un thème (data, archi_web, tech_env) à un autre, ainsi que de créer une seconde application Python qui permettrait de regrouper tous les résultats obtenus.

Les quatre scripts se trouvent dans le dossier ``scripts/proportion-KL-ressource-theme`` du repository Gitlab. Le script `proportion_stude`

nts.py permet d'extraire, à partir des logs étudiants, les proportions de transitions (ressource ou thème) pour chaque étudiant individuellement. Le script proportion_cursus.py agrège ensuite ces résultats par cursus afin d'obtenir des profils moyens représentatifs de chaque filière. Le script proportion_success.py segmente les étudiants selon leur réussite (réussite/échec) et calcule les proportions moyennes de transitions pour ces deux groupes. Enfin, le script divergence_KL_cursus.py compare chaque étudiant aux profils de cursus en calculant une divergence de Kullback-Leibler, permettant d'identifier le cursus auquel son comportement se rapproche le plus.

Navigation

Data view

☒ Resource

☐ Theme

Page

☒ Overview

☐ Student view

Ces scripts fonctionnent tous selon deux modes principaux, --ressource ou --theme, qui déterminent le type de transitions analysées (entre types de ressources ou entre thèmes pédagogiques), et s'appuient sur des fichiers d'entrée générés aux étapes précédentes pour produire des fichiers intermédiaires structurés.

L'ensemble des fichiers résultant de ces scripts sont stockés dans le dossier `docs/proportion-KL-ressource-theme`. Ils sont ensuite utilisés par l'application app_passage_ressource_theme.py pour être affichés

2. L'application Streamlit

Cette nouvelle application Python est divisée en deux pour pouvoir analyser d'un côté les passages Practice-Lecture, et d'un autre les transitions entre thèmes pédagogiques. Il est donc possible de choisir avec l'onglet de navigation les informations que l'on souhaite visualiser, et ce pour l'ensemble des étudiants brestois ou individuellement.

Dans la vue *Overview*, l'application propose une vision globale des comportements des étudiants à travers plusieurs visualisations complémentaires. On y trouve tout d'abord des graphiques en barres présentant les proportions moyennes de transitions pour chaque cursus, ce qui permet d'identifier rapidement les différences de comportement entre filières. Une seconde visualisation compare ensuite ces mêmes transitions entre les groupes d'étudiants en réussite et en échec, afin de mettre en évidence d'éventuelles corrélations entre parcours de navigation et performance académique. Enfin, une série de nuages de points permet d'observer, pour chaque transition, la répartition individuelle des étudiants en fonction de leur note, afin de pouvoir observer plus en détail les tendances globales.

Dans la vue *Student view*, l'application permet d'analyser en détail le comportement d'un étudiant spécifique. Pour un étudiant sélectionné, plusieurs graphiques comparent ses transitions à celles de son propre cursus ainsi qu'au groupe le plus proche selon la divergence KL, mettant en évidence ses similarités ou écarts. Une dernière visualisation le positionne également par rapport aux moyennes des groupes en réussite et en échec, afin de mieux situer son profil au regard des performances globales.

3. Premiers résultats obtenus

Arrivés à la fin du projet, nous n'avons pas eu le temps de mener une analyse approfondie de l'ensemble des résultats. Par ailleurs, ces visualisations permettent déjà de dégager quelques tendances intéressantes, qui pourraient être approfondies.

Sur la vue *Resource / Overview*, on observe tout d'abord que les transitions impliquant des ressources de type Lecture (notamment L-L) sont globalement les plus représentées, quel que soit le cursus. Cela suggère que les étudiants passent une part importante de leur temps sur des contenus théoriques, ce qui semble cohérent avec une phase d'apprentissage initiale. De plus, en comparant les groupes Réussite et Échec, on remarque que les étudiants en réussite ont légèrement plus tendance à rester dans des séquences de type Lecture, tandis que les étudiants en échec présentent des proportions plus élevées de transitions P-P, c'est-à-dire qu'il passe d'une activité pratique à une autre de manière directe. Cette dernière observation peut laisser penser que les étudiants qui enchaînent les travaux pratiques sans repasser par la théorie pourraient rencontrer plus de difficultés. Plusieurs hypothèses peuvent être avancées : un manque de consolidation des notions fondamentales, une tentative de compenser des lacunes en multipliant les exercices, tout en se disant que les cours théoriques seraient peut-être trop compliqués à aborder. À l'inverse, le fait d'alterner ou de revenir régulièrement vers des ressources de type Lecture pourrait favoriser une meilleure assimilation des concepts.

En revanche, pour les autres types de transitions (L-P et P-L), aucune tendance claire ne se dégage. Les résultats sont assez similaires entre les groupes et les cursus, ce qui ne permet pas de dégager un lien clair entre ces transitions et un bon ou mauvais résultat à l'évaluation intermédiaire.

Sur la vue *Overview - Theme*, les tendances sont globalement moins marquées que pour les types de ressources. On observe néanmoins que certains thèmes, comme data, semblent légèrement plus associés aux étudiants en réussite, tandis que d'autres, comme archi_web, sont un peu plus présents chez les étudiants en échec. Cependant, ces écarts restent relativement faibles et les comportements apparaissent assez homogènes entre les groupes. Les transitions entre thèmes ne font pas non plus ressortir de structure claire, ce qui suggère que le type de contenu (Lecture vs Practice) a probablement plus d'impact que le thème lui-même sur les performances.

Pattern mining

1. Objectif

L'objectif du pattern mining est d'identifier des séquences fréquentes de navigation dans les parcours des étudiants afin de mettre en évidence des stratégies d'apprentissage typiques. Contrairement aux analyses précédentes basées sur des transitions locales (Lecture → Practice), cette approche permet d'extraire des enchaînements complets d'actions. L'objectif est ensuite de comparer ces séquences entre les étudiants en réussite et en échec afin

d'identifier des comportements discriminants, c'est-à-dire des comportements significativement associés à la performance académique.

2. Méthode utilisée

Chaque étudiant est représenté par une séquence ordonnée de pages visitées. Sur cet ensemble de séquences, nous appliquons l'algorithme PrefixSpan (Prefix-projected Sequential pattern mining), qui permet d'extraire des sous-séquences fréquentes. Le principe de cet algorithme est d'explorer progressivement les séquences en partant des patterns les plus simples, puis en les étendant récursivement. À chaque étape, seules les séquences suffisamment fréquentes sont conservées, ce qui permet de réduire fortement l'espace de recherche grâce à un mécanisme de pruning.

Deux paramètres principaux sont utilisés. La longueur maximale des patterns est fixée à 3 afin de conserver des séquences interprétables correspondant à de courtes stratégies d'apprentissage. Le support minimum est fixé à 0.3, ce qui signifie qu'un pattern doit apparaître chez au moins 30 % des étudiants d'un groupe pour être retenu.

3. Pipeline de traitement

Le pipeline se décompose en plusieurs étapes simples. Les logs sont d'abord transformés en séquences d'actions par étudiant (`build_sequences.py`). Ces séquences sont ensuite encodées sous forme numérique (`encode_sequences.py`) et enrichies avec les informations de réussite (`merge_grades.py`). L'algorithme de pattern mining est alors appliqué (`pattern_mining.py`) séparément sur les groupes réussite et échec. Les résultats sont ensuite décodés (`decode_patterns.py`) afin d'obtenir des séquences lisibles, puis comparés (`discriminant_patterns.py`) pour identifier les patterns caractéristiques de chaque groupe.

4. Patterns discriminants

Après nettoyage (suppression des pages de type *home*), plusieurs patterns caractéristiques émergent.

Patterns associés à la réussite

On observe principalement des séquences de type :

lecture → practice → practice avancée

Exemples :

- lecture_sql → practice_sql → practice_advanced_sql
- lecture_jpa → practice_jpa → practice_jpa_advanced

Ces patterns traduisent une stratégie d'apprentissage structurée :

- acquisition des connaissances
- mise en pratique
- approfondissement

Patterns associés à l'échec

Les patterns observés sont plutôt de type :

practice → practice → correction ou activité → correction → activité

Exemples :

- practice_sql → practice_sql_correction
- activity_modeling → correction_modeling

Ces séquences peuvent indiquer :

- des difficultés persistantes
- une absence de retour vers les ressources théoriques
- une stratégie d'essais-erreurs

5. Premières interprétations

Après filtrage des pages non pertinentes (notamment les pages d'accueil), plusieurs tendances apparaissent. Les étudiants en réussite suivent majoritairement des séquences structurées combinant lecture et pratique, typiquement sous la forme « lecture → pratique → pratique avancée ». Ce type de pattern traduit une progression logique dans l'apprentissage, allant de l'acquisition des connaissances à leur application puis à leur approfondissement.

À l'inverse, les étudiants en échec présentent plus des séquences centrées sur la pratique ou les corrections, sans retour vers la théorie. Ces comportements peuvent refléter des difficultés à consolider les notions fondamentales, ainsi qu'une stratégie d'essais-erreurs moins efficace.

Ces résultats suggèrent que la réussite est associée à un apprentissage structuré et équilibré entre théorie et pratique, tandis que certaines séquences peuvent constituer des indicateurs précoces de difficulté.

D'autres approfondissements que nous aurons aimé explorer sont notamment le fait de vérifier si:

- Est-ce qu'il existe des personnes qui ont réussi sans suivre le graphe de prérequis?
- Est-ce qu'il y'a des patterns lectureA -> activityA très couplées? Afin de savoir si on a des activités qui sont faites sans avoir besoin de consulter le cours.

Pagerank

1. Objectif

L'objectif de cette analyse basée sur le PageRank est d'identifier les ressources centrales dans les parcours des étudiants. Contrairement aux approches séquentielles qui cherchent des motifs fréquents, le PageRank permet de mesurer le poids structurel et l'influence réelle de chaque notion au sein du flux d'apprentissage global. L'objectif est ensuite de comparer cette hiérarchie de ressources selon le profil des étudiants (cursus d'origine) et leurs performances (réussite vs échec) afin de déceler des stratégies d'exploration et des goulots d'étranglement spécifiques.

2. Méthode utilisée

Sachant que le principe mathématique de l'algorithme a déjà été défini, son application ici consiste à modéliser le cours comme un graphe orienté : les pages (cours, pratiques, activités) sont les nœuds, et les transitions réelles des étudiants entre ces pages constituent les liens. Le poids de chaque lien est défini par la fréquence de la transition.

L'algorithme PageRank (avec un facteur d'amortissement α standard de 0.85) est appliqué sur ces graphes pour attribuer un score d'importance à chaque ressource. Pour garantir la pertinence de l'analyse, un filtrage rigoureux est mis en place :

- Seules les transitions correspondant à un temps d'étude réaliste (entre 2 secondes et 1 heure) sont conservées.
- Les pages structurelles sans contenu pédagogique direct (home, index, project...) sont exclues du calcul.

3. Pipeline de traitement

Le pipeline se décompose en deux grandes phases via deux scripts dédiés. Dans un premier temps (`calcul_pagerank.py`), les logs bruts sont nettoyés, filtrés temporellement, puis transformés en graphes dirigés selon le groupe, le cursus et la performance (réussite pour une note ≥ 12 , échec sinon). Le script calcule les scores PageRank pour ces différents sous-graphes et génère pour chaque étudiant un indicateur de « qualité de navigation » correspondant à la valeur PageRank moyenne des pages qu'il a consultées. Dans un second temps (`analyse_pagerank.py`), ces données consolidées sont exploitées pour générer des visualisations statistiques (diagrammes en barres, heatmaps, boxplots) permettant de comparer visuellement le poids des ressources entre les différentes cohortes.

4. Ressources clés et profils de consultation

L'analyse visuelle des scores PageRank met en évidence des différences notables de comportement, qui viennent corroborer et enrichir nos analyses précédentes.

- **Différences d'importance selon les cursus :** La Heatmap et les diagrammes par cursus montrent que la notion de "ressource indispensable" dépend fortement du

bagage initial de l'étudiant. Par exemple, les profils Informatique convergent massivement vers la base (`practice_sql`, `lecture_conceptual_modeling`), tandis que les profils Mesures Physiques accordent un poids disproportionné à l'implémentation applicative avec `practice_spring_2tiers` en tête de leur graphe. L'analyse par boxplots révèle également que certains cursus compensent leurs lacunes par un volume d'activité (nombre de pages vues) beaucoup plus important.

- **Patterns associés à la réussite** : Chez les étudiants en réussite, le Top 10 des pages au plus fort PageRank montre un ancrage profond dans les concepts fondamentaux. On retrouve en tête de leur graphe :
 1. `practice_jpa`
 2. `lecture_normalization` et `lecture_conceptual_modeling`
 3. `practice_sql` et `activity_sql`
- **Patterns associés à l'échec** : À l'inverse, le graphe des étudiants en échec est fortement polarisé par des ressources d'implémentation technique spécifiques (frameworks). Leurs nœuds les plus lourds sont :
 1. `practice_jpa` (qui domine très largement le classement)
 2. `lecture_mvc_spring` Les concepts fondamentaux (comme la normalisation ou le SQL pur) sont relégués beaucoup plus bas dans la hiérarchie de leur graphe de navigation.

5. Premières interprétations

L'application du PageRank vient confirmer et éclairer les résultats obtenus lors de l'analyse des transitions et du pattern mining.

Les étudiants en réussite structurent leur apprentissage autour des concepts fondateurs de la donnée (Modélisation conceptuelle, Normalisation, SQL). Cela fait écho à notre observation précédente où le thème data était légèrement plus associé à la réussite. Leur apprentissage semble suivre la progression logique mise en évidence par le pattern mining (théorie → pratique → approfondissement), ce qui donne un PageRank élevé aux lectures fondamentales.

À l'inverse, le score PageRank extrêmement élevé de la page `practice_jpa` chez les étudiants en échec suggère un phénomène de « goulot d'étranglement ». Ces étudiants semblent buter sur l'implémentation technique avancée. Ce résultat s'aligne parfaitement avec notre observation des transitions : ces étudiants ont tendance à s'enfermer dans des boucles de type Practice-Practice (P-P) ou dans des stratégies d'essais-erreurs face aux corrections. Ils tentent de forcer la résolution technique (Spring, JPA) en y passant énormément de temps, sans s'appuyer suffisamment sur les pages de conception théorique préalables.

Synthèse

Ce projet d'analyse des parcours d'apprentissage (Learning Path Analysis) a permis d'explorer la manière dont les étudiants naviguent à travers les ressources pédagogiques.

En croisant trois approches analytiques complémentaires — l'étude des transitions locales, l'extraction de séquences fréquentes (pattern mining) et l'évaluation de l'importance structurelle des ressources (PageRank) — nous avons pu mettre en lumière plusieurs tendances comportementales qui semblent distinguer les parcours des étudiants en réussite de ceux en difficulté.

Les différentes méthodes employées tendent à converger vers une hypothèse commune : la réussite académique semble globalement associée à une démarche plus structurée. Les étudiants performants paraissent accorder une place importante à l'acquisition théorique initiale. Leur navigation illustre souvent une progression classique, allant de l'assimilation du cours vers la mise en pratique, puis vers l'approfondissement (comme le suggère le pattern `lecture → practice → practice avancée`). L'analyse par PageRank vient appuyer cette observation en indiquant que leur apprentissage s'ancre généralement sur les concepts fondateurs (Modélisation conceptuelle, Normalisation, SQL), qui constituent des points de passage clés dans leur parcours.

À l'inverse, les parcours associés à l'échec laissent entrevoir des stratégies d'apprentissage potentiellement plus fragmentées. On observe chez ces étudiants une tendance plus marquée à enchaîner directement les mises en pratique (transitions P-P) ou à consulter de manière répétée des activités et leurs corrections, avec moins de retours visibles vers la théorie. L'algorithme PageRank suggère que cette difficulté à consolider les bases pourrait contribuer à créer des goulots d'étranglement, notamment lors du passage à des implémentations techniques complexes (comme JPA ou Spring MVC). Face à ces obstacles, la stratégie observée semble parfois être de multiplier les tentatives pratiques sur la même ressource plutôt que de revoir les concepts théoriques sous-jacents.

Enfin, notre étude souligne que le comportement de navigation est loin d'être uniforme et qu'il semble influencé par le cursus d'origine des étudiants. La notion de "ressource indispensable" varie visiblement selon les prérequis de chacun : le besoin de revoir les bases de données ressort davantage pour certains profils, tandis que d'autres filières paraissent concentrer une grande partie de leurs efforts sur l'architecture logicielle.